

MÓDULO

Ingeniería y Analítica de Grandes Cantidades de Datos

Proyecto Big Data

Grupo 5: Uso de Bicicletas (Londres)

INTEGRANTES

Nahin Jussephe Cevallos Vines Annabella Noelia Sanchez Guzman

Martha Maritza Duran Navarrete Jesus David Suarez Aspiazu

Isabella Ivonne Martin Pimentel Angelo Saul Zurita Guerrero

Juan Andres Munizaga Torres

18 de septiembre de 2026

Código fuente: <https://github.com/Jmuniz27/proyecto-bigdata-g5-londres-bicis>

Índice

1. Resumen ejecutivo	2
2. Dataset y versiones	2
3. Metodología	3
3.1. Las tres preguntas	3
3.2. Las tres herramientas	3
3.3. Protocolo de ejecución independiente	4
3.4. Validación cruzada	4
4. Equipos de cómputo	4
4.1. Versiones de software	4
5. Fase 2: Línea base	5
5.1. Tiempo total por herramienta y versión	5
5.2. Por qué ese orden	5
5.3. Dónde se va el tiempo	6
6. Fase 3: Optimización	7
6.1. Diagnóstico	7
6.2. La optimización elegida	7
6.3. Impacto medido	7
6.4. Amortización del ETL	9
6.5. Nota sobre SQLite en la versión XL de Pc_Nahin	9
6.6. Por qué SQLite gana menos que las demás	9
7. Comparación entre equipos	10
7.1. Dónde se rompe cada máquina	10
7.2. Las tres lecturas	10
7.3. Escalado	11
8. Respuestas a las tres preguntas	11
8.1. Q1: Demanda por hora del día y día de la semana	11
8.2. Q2: Estaciones con mayor desequilibrio	12
8.3. Q3: Concentración del tráfico en rutas	13
9. Diseño del pipeline ETL	15
9.1. Herramientas y servicios por etapa	16
10. Análisis de costos	16
10.1. Costo del pipeline en la nube (mensual, estado estable)	17
10.2. Costo ya medido: cómputo local y tiempo de persona	18
11. Problemas encontrados	18
12. Limitaciones metodológicas	19
13. Conclusiones	19

1. Resumen ejecutivo

Tres motores de datos con arquitecturas distintas responden las mismas tres preguntas analíticas sobre 38.2 millones de viajes del sistema público de bicicletas de Londres, medidos en tres computadoras y en dos etapas: leyendo el CSV original y leyendo un artefacto pre-procesado.

Se compararon **Pandas** (DataFrame en memoria, columnar sobre NumPy, mono-hilo), **DuckDB** (motor OLAP columnar embebido, vectorizado y multi-hilo) y **SQLite** (motor OLTP embebido, orientado a filas). Cada combinación de versión, herramienta y pregunta se ejecutó de forma independiente, cargando el archivo desde cero, con un presupuesto de 10 minutos por ejecución.

Tres hallazgos sostienen el trabajo:

1. **El umbral de Big Data no es una cifra de filas ni de gigabytes.** La versión XL resultó imposible en una máquina de 15.7 GB de RAM y perfectamente manejable en una de 8 GB. Big Data es una propiedad de la relación entre datos, representación y hardware.
2. **Cambiar la representación mueve ese umbral sin tocar el hardware.** El equipo que falló leyendo el CSV de 4.7 GB completó la misma carga de trabajo en 6.0 segundos sobre el artefacto optimizado.
3. **La arquitectura de almacenamiento pesa más que las especificaciones.** DuckDB resolvió el dataset completo en 2.7 segundos en la máquina de menor RAM del grupo, mientras SQLite necesitaba varios minutos en la de 40 GB. Un índice B-tree no convierte un motor OLTP en columnar.

2. Dataset y versiones

La fuente es el conjunto [Bikeshare usage in London and Taipei](#) de Kaggle. **El alcance de este trabajo es únicamente la red de Londres**; los datos de Taipéi quedan fuera por decisión de equipo.

Se trabajó con el histórico de viajes en cinco versiones de tamaño creciente, más `london_stations.csv`, un catálogo de 802 estaciones con nombre, latitud y longitud.

Cuadro 1: Versiones disponibles del dataset

Versión	Archivo	Tamaño (GB)	Filas	Factor vs. XS
XS	<code>london_xs.csv</code>	0.049	398,075	1.0×
S	<code>london_s.csv</code>	0.488	3,972,436	10.0×
M	<code>london_m.csv</code>	1.181	9,590,698	24.1×
L	<code>london_l.csv</code>	2.363	19,148,881	48.1×
XL	<code>london.csv</code>	4.725	38,215,560	96.0×

El esquema tiene nueve columnas: `rental_id`, `duration`, `bike_id`, `start_rental_date_time`, `end_rental_date_time`, `start_station_id`, `start_station_name`, `end_station_id`, `end_station_name`.

La exploración inicial, hecha con DuckDB en streaming para no cargar los archivos grandes en memoria, detectó cuatro problemas de calidad:

- `end_station_id` tiene nulos, que corresponden a viajes sin devolución registrada. Se excluyen de las llegadas y de los pares origen-destino.
- `duration` contiene ceros y valores extremos de varios días. No intervienen en las tres preguntas, pero se documentan.

- `start_station_id` es entero mientras `end_station_id` se infiere como `DOUBLE` por causa de los nulos. Hay que castear explícitamente para que los identificadores comparen igual en las tres herramientas.
- El catálogo tiene 802 estaciones, pero Q2 y Q3 (Sección 8) reportan 808 identificadores de estación distintos, porque esa cifra sale directo de los `station_id` que aparecen como origen o destino en los viajes, no del catálogo. Siete `station_id` (391, 346, 304, 434, 241, 825, 823) no están en `london_stations.csv`; la 391 por sí sola acumula 9,050 viajes. El join contra el catálogo es left join y las rellena con la etiqueta (estación N), así que no rompen Q2 ni Q3, pero al no tener latitud ni longitud quedan fuera de la Figura 7 (la estación 391 incluida), y su nombre se pierde de forma irrecuperable en la proyección a 4 columnas de la Fase 3 (Sección 6.1).

El rango de fechas cambia con la versión: las versiones chicas cubren pocas semanas y las grandes cubren más meses. Eso altera la interpretación de la estacionalidad, no el método.

3. Metodología

3.1. Las tres preguntas

La propuesta inicial planteó siete preguntas exploratorias; se eligieron las tres primeras porque las tres se resuelven con un `GROUP BY` sobre las mismas columnas, lo que aísla el efecto de la herramienta. Las cuatro restantes (duración, geografía, período de fiestas y distancia/velocidad) quedaron fuera del alcance.

Cuadro 2: Preguntas analíticas del proyecto

#	Pregunta	Salida
Q1	¿Cómo varía la demanda de viajes por hora del día y día de la semana?	168 combinaciones día × hora
Q2	¿Qué estaciones tienen mayor desequilibrio entre llegadas y salidas?	808 estaciones con actividad
Q3	¿Existen rutas origen-destino que concentran gran parte del tráfico?	510,672 rutas distintas

3.2. Las tres herramientas

Cuadro 3: Herramientas comparadas

Herramienta	Arquitectura	Por qué está en la comparación
Pandas	DataFrame en memoria, columnar sobre NumPy, mono-hilo	Caso base: rápido mientras el dataset quepa en RAM
DuckDB	Motor OLAP columnar embebido, vectorizado y multi-hilo	Diseñado exactamente para este tipo de agregación
SQLite	Motor OLTP embebido, orientado a filas	Misma interfaz SQL, arquitectura de almacenamiento opuesta

SQLite es la tercera herramienta y aporta el contraste más informativo del trabajo: comparte el lenguaje con DuckDB pero no su modelo de almacenamiento, así que aísla el efecto de la arquitectura frente al del lenguaje de consulta.

3.3. Protocolo de ejecución independiente

Cada combinación de versión, herramienta y pregunta es una **ejecución independiente que arranca desde el archivo**: se carga desde cero y después se corre la consulta. El tiempo reportado es carga + query, y ese es el número que se compara contra el límite de 10 minutos. El límite se verifica al terminar cada ejecución: la que lo supera se marca EXCEDE y las preguntas siguientes de esa herramienta se omiten.

La razón es que SQLite no conserva el archivo cargado entre consultas, a diferencia de Pandas y DuckDB, que mantienen los datos en memoria. El mismo protocolo para las tres evita que alguna se beneficie de reutilizar una carga que otra tuvo que repetir.

Otras reglas que sostienen la honestidad de la medición:

- La carga a SQLite **no usa Pandas**. Se lee el CSV en streaming con el módulo `csv` de la librería estándar y se inserta por lotes de 200,000 filas con `executemany`. Usar `df.to_sql()` mediría a Pandas disfrazado de SQLite.
- DuckDB **materializa** la tabla con `CREATE TABLE ... AS SELECT`, en vez de leer el CSV de forma perezosa, para competir en igualdad de condiciones con `pd.read_csv()`.
- La base SQLite se crea desde cero en cada ejecución y se borra al terminar.
- El pico de RAM se captura con un hilo que muestrea el proceso cada 50 ms. Medir solo antes y después perdería el pico transitorio que ocurre dentro de la lectura.
- Los días de la semana se normalizan a lunes = 0 en las tres herramientas, porque cada motor los numera distinto.

3.4. Validación cruzada

Un benchmark solo vale si las tres herramientas responden lo mismo. Los resultados se comparan celda a celda contra Pandas como referencia, con tolerancia numérica en las columnas de porcentaje, y se verifica el cuadro aritmético: la suma de viajes de Q1 debe igualar el número de filas del archivo, y las llegadas de Q2 deben igualar el total de Q3. **Las tres herramientas produjeron resultados idénticos en todas las versiones que completaron.**

4. Equipos de cómputo

El barrido se corrió en tres máquinas con perfiles deliberadamente distintos. Esa diversidad es lo que permite responder dónde empieza a ser Big Data, porque la respuesta cambia con el equipo.

4.1. Versiones de software

Las versiones no son idénticas entre equipos. La diferencia es menor frente a las brechas de orden de magnitud que se observan, pero se declara por transparencia.

Las tres máquinas corren DuckDB 1.5.5, así que las diferencias de rendimiento entre ellas no se explican por la versión del motor analítico.

Cuadro 4: Ficha técnica de los equipos utilizados

Equipo	Sistema	Procesador	Núcleos (físicos/lógicos)	RAM	Versiones corrientes
Pc_Jesus	macOS Darwin 27.0 (arm64)	Apple arm, 3.20 GHz	8 / 8	8.0 GB	M, L, XL
Pc_Martha	Windows (AMD64)	11 Intel i7 gen 13, 1.70 GHz	10 / 12	15.7 GB	XS, S, M, L, XL
Pc_Nahin	Windows (AMD64)	11 Intel Core Ultra 9 185H, 2.30 GHz	16 / 22	39.4 GB	M, L, XL

Cuadro 5: Versiones de software por equipo

Equipo	Python	pandas	duckdb	sqlite	numpy
Pc_Jesus	3.14.3	3.0.5	1.5.5	3.50.4	2.5.3
Pc_Martha	3.12.10	3.0.2	1.5.5	3.49.1	2.4.4
Pc_Nahin	3.14.0	3.0.1	1.5.5	3.50.4	2.4.3

5. Fase 2: Línea base

De la versión S en adelante, DuckDB es entre 4 y 11 veces más rápido que Pandas y entre 17 y 30 veces más rápido que SQLite sobre el mismo CSV. El orden se mantiene en las tres máquinas y en todas las versiones.

5.1. Tiempo total por herramienta y versión

Suma de las tres preguntas, en segundos. Cada celda es carga + query acumulado. El desglose por pregunta de cada equipo está en los archivos `benchmarks_*.csv` del repositorio.

Cuadro 6: Tiempo total (carga + query) por versión, equipo y herramienta

Versión	Equipo	Pandas	DuckDB	SQLite
XS	Pc_Martha	1.9	0.7	5.8
S	Pc_Martha	29.5	4.0	97.2
M	Pc_Jesus	34.5	5.0	108.2
M	Pc_Martha	50.0	6.7	164.6
M	Pc_Nahin	143.1	15.3	445.0
L	Pc_Jesus	79.1	11.5	232.8
L	Pc_Martha	106.5	15.3	404.0
L	Pc_Nahin	288.1	25.9	776.9
XL	Pc_Jesus	195.4	27.3	472.6
XL	Pc_Martha	falló	falló	falló
XL	Pc_Nahin	501.4	122.3	excedió

5.2. Por qué ese orden

DuckDB almacena por columnas y ejecuta de forma vectorizada y multi-hilo. Para un GROUP BY lee únicamente las dos o tres columnas que necesita; el resto del ancho de fila nunca toca el disco ni la RAM.

Pandas también es columnar en memoria y vectorizado sobre NumPy, pero es mono-hilo y paga materializar las nueve columnas, incluidas las dos de texto con los nombres de estación, que son las más caras de parsear y las que más memoria ocupan.

SQLite está orientado a filas. Un `GROUP BY` recorre cada registro completo y parsea los timestamps con `strftime` fila por fila. Es el comportamiento esperado: SQLite está optimizado para OLTP, es decir, buscar e insertar pocas filas por clave, no para agregar decenas de millones.

5.3. Dónde se va el tiempo

El desglose entre carga y consulta es la observación que justifica toda la Fase 3. En la versión XL sobre Pc_Jesus:

Cuadro 7: Desglose carga vs. query, versión XL, Pc_Jesus

Herramienta	Pregunta	Carga (s)	Query (s)	% en carga
Pandas	Q1	56.7	2.7	95 %
Pandas	Q3	57.2	21.6	73 %
DuckDB	Q1	9.0	0.3	97 %
DuckDB	Q3	8.1	1.4	85 %
SQLite	Q1	99.8	28.6	78 %
SQLite	Q2	108.8	82.6	57 %

La carga domina en todos los casos. Y como el protocolo obliga a recargar el archivo en cada pregunta, ese costo se paga tres veces. **El formato de almacenamiento es, entonces, la palanca de optimización más rentable disponible.**




Figura 1: Reparto entre tiempo de carga y tiempo de consulta, Pc_Jesus.




Figura 2: Escalado log-log del tiempo total contra el número de filas, Pc_Jesus.

6. Fase 3: Optimización

Un paso de ETL ejecutado una sola vez por versión reduce el tiempo total entre 20× y 57× en Pandas, entre 3× y 11× en DuckDB y hasta 2× en SQLite; en Pandas y DuckDB se amortiza antes de completar una sola corrida.

6.1. Diagnóstico

De la Fase 2 salen cuatro hechos que definen qué optimizar:

1. La carga domina el tiempo total, y como cada pregunta recarga el archivo, ese costo se paga tres veces.
2. Se leen nueve columnas y solo se usan tres: `start_rental_date_time`, `start_station_id` y `end_station_id`. Las dos columnas de nombres de estación son las más pesadas y en general son redundantes, porque ya están normalizadas en el catálogo. La excepción son las 7 estaciones sin entrada en `london_stations.csv` (Sección 2): para esas, la columna de nombre es la única fuente y su valor se pierde de forma irrecuperable al proyectar a 4 columnas.
3. Los tipos están sobredimensionados. Los identificadores de estación llegan a ~800 y viven en INT64 o DOUBLE; la hora y el día se recalculan desde el timestamp en cada consulta.
4. SQLite recorre filas completas y parsea timestamps con `strftime` registro por registro.

6.2. La optimización elegida

Pre-procesar a un artefacto columnar con tipos reducidos, sobre el cual corren después todas las consultas.

El artefacto Parquet de la versión XL pesa 89 MB frente a los 4,725 MB del CSV original: una reducción de 53×.

6.3. Impacto medido

Tiempo total de las tres preguntas, antes y después, en segundos.

En Pc_Jesus, versión XL, las mejoras por pregunta llegan a 110× en Pandas Q2 (57.1 s a 0.52 s).

Cuadro 8: Decisiones de la optimización

Decisión	Por qué mejora el rendimiento
Formato Parquet, para Pandas y DuckDB	Binario y columnar: el motor lee solo las columnas de la consulta y no parsea texto. Trae esquema y tipos embebidos, así que no hay inferencia.
CSV estrecho de 4 enteros, para SQLite	SQLite no lee Parquet. Su artefacto es un CSV con cuatro columnas numéricas cortas: el parseo por fila se abarata frente a nueve campos con dos cadenas largas y dos timestamps.
Proyección a 4 columnas	Se eliminan <code>rental_id</code> , <code>bike_id</code> , <code>duration</code> , los dos nombres y <code>end_rental_date_time</code> . Menos bytes leídos por fila.
Pre-cálculo de <code>dia_semana</code> y hora	Se hace una vez en el ETL en vez de en cada consulta, y se guardan como <code>TINYINT</code> .
Tipos reducidos (<code>TINYINT</code> , <code>SMALLINT</code>)	Menos memoria por fila y mejor aprovechamiento de caché.
Ordenar por <code>dia_semana</code> , <code>hora</code>	Potencia la codificación RLE de Parquet y reduce el tamaño en disco.
Índice covering por pregunta en SQLite	Cada consulta recibe únicamente el índice que necesita, en vez de construir tres y usar uno.

Cuadro 9: Impacto de la optimización por versión y equipo

Versión	Equipo	Pandas	DuckDB	SQLite	ETL (s)
M	Pc_Jesus	34.5 a 0.7 (48×)	5.0 a 0.6 (8×)	108.2 a 61.7 (1.8×)	8.4
M	Pc_Martha	50.0 a 2.5 (20×)	6.7 a 2.0 (3×)	164.6 a 184.4 (0.9×)	2.9
M	Pc_Nahin	143.1 a 3.9 (36×)	15.3 a 3.8 (4×)	445.0 a 221.7 (2.0×)	8.4
L	Pc_Jesus	79.1 a 3.2 (25×)	11.5 a 1.0 (11×)	232.8 a 129.4 (1.8×)	2.6
L	Pc_Martha	106.5 a 4.6 (23×)	15.3 a 2.7 (6×)	404.0 a 304.1 (1.3×)	5.4
L	Pc_Nahin	288.1 a 6.0 (48×)	25.9 a 6.5 (4×)	776.9 a 483.8 (1.6×)	5.4
XL	Pc_Jesus	195.4 a 3.4 (57×)	27.3 a 2.7 (10×)	472.6 a 291.5 (1.6×)	6.3
XL	Pc_Martha	falló a 6.0	falló a 3.1	falló a 486.0	10.6
XL	Pc_Nahin	501.4 a 14.4 (35×)	122.3 a 14.6 (8×)	ver nota §6.5	14.8

6.4. Amortización del ETL

El ETL se paga una sola vez y el ahorro se cobra en cada corrida posterior. En la versión XL sobre Pc_Jesus, el ETL cuesta 6.3 s y ahorra 191.9 s por corrida en Pandas: **se amortiza en el 3 % de una corrida**. En DuckDB, que ya era rápido, el ahorro es de 24.6 s por corrida y la amortización toma el 26 % de una corrida. En un pipeline que se ejecuta a diario la inversión se recupera de inmediato; para un análisis único aislado, el cálculo es menos evidente, y ese contraste es parte del resultado.

6.5. Nota sobre SQLite en la versión XL de Pc_Nahin

Una lectura superficial de la gráfica sugiere que la optimización empeoró SQLite en esa máquina: 1,099.2 s en base contra 1,157.8 s optimizado. **La comparación no es válida**. En la etapa base, Q2 tardó 678.7 s y quedó marcada como EXCEDE por superar los 10 minutos, lo que hizo que el harness omitiera automáticamente Q3. Ese 1,099.2 es la suma de **dos** preguntas; el 1,157.8 es la suma de **tres**.

Comparando pregunta contra pregunta:

Cuadro 10: SQLite XL en Pc_Nahin, comparación pregunta contra pregunta

Pregunta	Base (s)	Optimizado (s)	Mejora
Q1	420.5	237.8	1.77×
Q2	678.7 (EXCEDE)	539.5	1.26×
Q3	no ejecutada	380.5	de imposible a viable

La optimización no solo ayudó: convirtió una ejecución que violaba el límite del enunciado en una que lo cumple.

6.6. Por qué SQLite gana menos que las demás

SQLite es la herramienta más castigada en la línea base y la que más gana en términos absolutos con el esquema estrecho. Pero **su ingesta sigue siendo proporcional al número de filas**: el `executemany` tiene que insertar los mismos millones de registros, solo que con campos más baratos de parsear. Por eso su mejora es grande pero no del orden de la de Pandas, y sigue sin alcanzar a DuckDB.

En Pc_Martha, versión M, la optimización incluso resultó marginalmente más lenta (164.6 s contra 184.4 s). La causa es que construir el índice covering sobre 9.6 millones de filas cuesta más de lo que ahorra el parseo del CSV estrecho en esa máquina. **Una optimización no es universalmente buena: su valor depende de dónde estaba el cuello de botella.**




Figura 3: Impacto de la optimización por herramienta, Pc_Jesus (base vs. optimizado).

7. Comparación entre equipos

Esta es la sección que responde la pregunta central del módulo: **¿en qué punto un problema se vuelve Big Data?** La respuesta que arrojan las mediciones es que no existe un punto, sino un umbral distinto por máquina y por representación de los datos.

7.1. Dónde se rompe cada máquina

Cuadro 11: Punto de quiebre por equipo

Equipo	RAM	Punto de quiebre en línea base	Con el artefacto optimizado
Pc_Jesus	8.0 GB	Ninguno. Completó M, L y XL en las tres herramientas	Completó todo
Pc_Martha	15.7 GB	Falló en XL a los 17 minutos , antes de terminar de leer el CSV	Completó XL en 6.0 s con Pandas
Pc_Nahin	39.4 GB	SQLite cruzó los 10 minutos en XL Q2 (678.7 s) y arrastró la omisión de Q3	Completó las tres preguntas

7.2. Las tres lecturas

La máquina con menos RAM sobrevivió donde una con el doble falló. El MacBook de 8 GB completó la versión XL en las tres herramientas, mientras el equipo de 15.7 GB abortó leyendo el mismo archivo. La memoria unificada y la velocidad del SSD compensaron la diferencia nominal de RAM. Esto descarta la lectura ingenua de que más memoria significa mayor capacidad de procesamiento.

Cambiar la representación movió el umbral sin tocar el hardware. La misma Pc_Martha que no pudo leer el CSV de 4.7 GB procesó la versión XL en 6.0 segundos sobre el Parquet. El dataset no cambió, la máquina no cambió, solo cambió cómo estaban escritos los bytes. Si el umbral de Big Data se puede mover con un paso de ETL, entonces el umbral nunca fue una propiedad del dataset.

La arquitectura del motor domina sobre las especificaciones del equipo. DuckDB en la máquina de 8 GB (2.7 s en XL optimizado) superó ampliamente a SQLite en la máquina de 40 GB

(varios minutos). Estructurar bien los datos y elegir un motor analítico adecuado rinde más que agregar memoria.

7.3. Escalado

En escala logarítmica, una recta de pendiente 1 indica escalado lineal $O(n)$. Lo relevante no es la pendiente sino dónde se rompe la linealidad: cuando los datos dejan de caber cómodamente en RAM, el sistema pagina a disco y la curva se dispara. Ese quiebre es distinto en cada máquina y es, precisamente, la frontera del Big Data para ese equipo.

8. Respuestas a las tres preguntas

Las tres herramientas producen resultados idénticos, ya validados celda a celda, así que las respuestas se calculan una sola vez sobre la **versión XL: 38,215,560 viajes**, la más grande disponible.

8.1. Q1: Demanda por hora del día y día de la semana

El patrón es bimodal en días laborables y unimodal en fin de semana. La forma de las dos curvas es distinta, y esa diferencia es la respuesta.

De lunes a viernes aparecen dos picos de desplazamiento al trabajo: **08:00 h** con un promedio de 710,450 viajes y **17:00-18:00 h** con 660,092 y 606,309. Sábado y domingo tienen un único máximo aplanado a las **14:00 h**, con 439,431 viajes promedio: uso recreativo, no de transporte.

Cuadro 12: Hora pico y total por día de la semana

Día	Hora pico	Viajes en la hora pico	Total del día
Lunes	17:00	672,240	5,590,150
Martes	08:00	768,730	5,902,367
Miércoles	08:00	741,295	5,795,257
Jueves	08:00	742,080	5,795,656
Viernes	08:00	645,178	5,633,146
Sábado	14:00	442,283	4,914,592
Domingo	14:00	436,579	4,584,392

El pico laborable es 1.62 veces el pico de fin de semana. El valle nocturno está a las 03:00 h con 8,638 viajes promedio, y la franja de 00:00 a 05:00 h concentra apenas el **2.0 % del uso semanal**.

Uso operativo: las horas pico marcan cuándo la flota debe estar completa. La franja nocturna, con un 2 % del tráfico, es la ventana natural para mantenimiento y rebalanceo sin afectar el servicio.

Una advertencia de interpretación: el rango de fechas depende de la versión. Las versiones chicas cubren pocas semanas y pueden caer en período navideño, donde el patrón laborable aparece atenuado porque varios días hábiles son feriados. Comparar el mapa de calor entre versiones es en sí mismo un resultado, porque muestra que con pocos datos se puede llegar a una conclusión equivocada sobre estacionalidad.




Figura 4: Mapa de calor de viajes por día de la semana y hora, versión XL.




Figura 5: Perfil horario: días laborables vs. fin de semana, versión XL.

8.2. Q2: Estaciones con mayor desequilibrio

El desbalance sigue el patrón radial clásico: **déficit en nodos de transporte y periferia residencial, superávit en el núcleo financiero y comercial**. Con $\text{neto} = \text{llegadas} - \text{salidas}$, un valor negativo significa que la estación se vacía y hay que abastecerla; uno positivo, que se satura y hay que retirar bicicletas.

Cuadro 13: Las cinco estaciones que más se vacían

Estación	Salidas	Llegadas	Neto	Desequilibrio
Waterloo Station 2, Waterloo	125,584	87,133	-38,451	-18.1 %
Eagle Wharf Road, Hoxton	107,628	86,866	-20,762	-10.7 %
Cloudesley Road, Angel	43,919	26,874	-17,045	-24.1 %
Knightsbridge, Hyde Park	51,202	37,693	-13,509	-15.2 %
Notting Hill Gate Station, Notting Hill	89,800	77,283	-12,517	-7.5 %

Waterloo Station encabeza el déficit, lo que confirma el patrón: la gente llega en tren y toma una bicicleta hacia el centro por la mañana. Holborn, Borough y St. James's son distritos de oficinas, y ahí es donde esas bicicletas terminan.

Magnitud absoluta contra magnitud relativa. El neto ordena por volumen, pero el porcentaje revela estaciones medianas con desbalance proporcional severo. Filtrando a estaciones con más de 20,000 viajes, los casos más críticos en términos relativos son **New North Road 1, Hoxton** (-26.9 %), **Risinghill Street, Angel** (-25.2 %) y **Cloudesley Road, Angel** (-24.1 %). El barrio de Angel aparece tres veces: es una zona residencial que se vacía sistemáticamente cada mañana. Para operaciones el porcentaje suele importar más que el absoluto, porque una estación que pierde una cuarta parte de su inventario está vacía buena parte del día.

Cuadro 14: Las cinco estaciones que más se saturan

Estación	Salidas	Llegadas	Neto	Desequilibrio
Hop Exchange, The Borough	176,231	237,045	+60,814	+14.7 %
Holborn Circus, Holborn	117,818	174,057	+56,239	+19.3 %
St. James's Square, St. James's	99,768	131,601	+31,833	+13.8 %
Brushfield Street, Liverpool Street	147,822	178,519	+30,697	+9.4 %
Soho Square, Soho	123,236	146,180	+22,944	+8.5 %

Sesgo declarado: 68,213 viajes (0.18 % del total) no tienen estación de destino registrada. Cuentan como salida y no como llegada, así que empujan el neto hacia el déficit. El efecto es pequeño frente a las magnitudes reportadas, pero existe.

Estaciones sin coordenadas. Las 7 estaciones fuera del catálogo (Sección 2) no tienen latitud ni longitud, así que quedan fuera de la Figura 7. Su neto (entre -19 y 934) tampoco entra en los 15 extremos de cada lado que muestra la Figura 6, así que ninguna de las dos figuras las representa; solo quedan en la tabla completa que produce el harness.




Figura 6: Estaciones con mayor déficit y superávit, versión XL.




Figura 7: Mapa geográfico del desbalance por estación, versión XL.

8.3. Q3: Concentración del tráfico en rutas

Sí hay concentración, pero no es un Pareto 80/20: la forma es de cola extremadamente larga. Sobre 652,864 pares origen-destino teóricamente posibles (808 estaciones al cuadrado), solo 510,672 aparecen alguna vez. Las **1,000 rutas más transitadas concentran el 9.6 % de todos los viajes**, y las 20 primeras apenas el 1.35 %.

Tres lecturas:

1. **Las rutas circulares dominan el top y no son viajes de transporte.** Las nueve rutas más transitadas tienen origen igual a destino, y todas están en parques: Hyde Park, Kensington Gardens y el Queen Elizabeth Olympic Park. Son paseos recreativos, no desplazamientos. En las primeras 1,000 rutas hay 208 circulares que suman 1,026,226 viajes. Mezclarlas con los desplazamientos punto a punto distorsiona cualquier conclusión sobre movilidad, así que se marcan aparte.

Cuadro 15: Rutas más transitadas, versión XL

#	Ruta	Viajes	% del total
1	Hyde Park Corner → Hyde Park Corner	72,625	0.190 %
2	Aquatic Centre → Aquatic Centre (Olympic Park)	67,661	0.177 %
3	Albert Gate → Albert Gate (Hyde Park)	42,049	0.110 %
4	Black Lion Gate → Black Lion Gate (Kensington Gardens)	40,221	0.105 %
5	Triangle Car Park → Triangle Car Park (Hyde Park)	35,652	0.093 %
10	Hyde Park Corner → Triangle Car Park	15,739	0.041 %
11	Hyde Park Corner → Albert Gate	15,405	0.040 %

2. **Los corredores estructurales aparecen después.** Las rutas no circulares del top conectan puntos dentro de los mismos parques o nodos de transporte con distritos de oficinas. Son el último tramo del trayecto al trabajo y candidatas naturales a carril exclusivo o a más capacidad de anclajes.
3. **La cola larga justifica la red.** Que ninguna ruta individual supere el 0.2 % del tráfico significa que el valor del sistema está en la cobertura, no en unos pocos corredores. Optimizar unas decenas de rutas tiene impacto local; mantener la red completa es lo que la hace útil como red.

Relación entre Q2 y Q3. Una ruta asimétrica, con mucho tráfico A→B y poco B→A, es la **causa** del desequilibrio que Q2 mide como **efecto**. Cruzar ambas identifica qué corredor concreto genera cada estación deficitaria, que es la información que necesita el equipo de rebalanceo. Y cruzar Q2 con Q1 daría la ventana horaria en que conviene intervenir, porque una estación puede vaciarse por la mañana y llenarse por la tarde.




Figura 8: Top 20 rutas más transitadas, versión XL.




Figura 9: Curva de concentración (Pareto) del tráfico por ruta, versión XL.

9. Diseño del pipeline ETL

El enunciado pide únicamente el diagrama, sin implementación. Lo que sigue es la propuesta, sobre Databricks + Azure.

Propósito: un sistema de rebalanceo predictivo. El problema de negocio sale de la Sección 8: sin un sistema así, el rebalanceo es reactivo, los camiones salen cuando alguien reporta una estación sin bicicletas o sin anclajes libres. El desbalance medido no es aleatorio: Waterloo Station 2 pierde 38,451 bicicletas netas, Hop Exchange acumula 60,814 de exceso, y Angel se vacía sistemáticamente cada mañana. El patrón es estable y, por lo tanto, predecible.

El pipeline convierte el flujo mensual de viajes en **órdenes de rebalanceo**: cruza el desequilibrio por estación (Q2) con el perfil horario (Q1) para estimar cuántas bicicletas faltarán o sobrarán en cada estación y franja del día, y con la matriz origen-destino (Q3) identifica el corredor que lo causa. La salida es accionable: qué estaciones visitar, en qué orden y cuántas bicicletas mover, dentro de la ventana 00:00–05:00 h (2 % del tráfico). Las tres preguntas dejan de ser un ejercicio y pasan a ser las tablas de la capa oro que alimentan esa decisión.

Se asume ingesta periódica: un archivo mensual de viajes nuevos, tamaño similar a la versión S (0.488 GB, 3.97 millones de filas). Con esa cadencia, la capa bronce alcanza el tamaño de la versión XL (4.725 GB) hacia el mes 10, estado estable usado en el análisis de costos de la Sección 10.




Figura 10: Pipeline ETL propuesto sobre Databricks + Azure, capas medallón (bronce/plata/oro) en Delta Lake sobre Azure Data Lake Storage Gen2, con Databricks Jobs como motor de transformación, Unity Catalog como catálogo de esquema y Databricks SQL Serverless + Power BI para el consumo. Íconos oficiales de Microsoft Azure, Databricks y Power BI.

9.1. Herramientas y servicios por etapa

Cuadro 16: Servicios de Databricks sobre Azure asignados a cada etapa del pipeline

Etapa	Servicio	Por qué esa herramienta
Orquestación	Databricks Workflows (Jobs)	Programa el job mensual sobre el mismo clúster que ejecuta el ETL. No hay un servicio de orquestación aparte encendido todo el tiempo.
Ingesta / Bronce	ADLS Gen2 (contenedor bronze/)	Almacenamiento jerárquico, barato y duradero para el CSV tal cual llega. También aloja el catálogo de estaciones.
Limpieza y transformación	Databricks Jobs (notebook PySpark)	Motor Spark administrado que resuelve casteo, nulos y proyección a 4 columnas. Es el mismo trabajo de Fase 3, escalado a un job programado.
Plata	ADLS Gen2 (silver/), Delta Lake	Sigue la decisión de Fase 3, con 53× de reducción frente al CSV. Delta añade versionado y transacciones ACID sobre ese mismo Parquet.
Catálogo de esquema	Unity Catalog	Registra el esquema de plata y oro con control de acceso centralizado, sin definir tablas a mano.
Agregación / Oro	Databricks Jobs (mismo notebook)	Calcula Q1, Q2 y Q3, las cruza en la tabla de órdenes de rebalanceo (estación, franja, bicicletas a mover) y escribe todo como Delta pequeño en gold/.
Consumo	Databricks SQL (Serverless) + Power BI	El equipo de rebalanceo consulta las órdenes en un tablero. El warehouse arranca en segundos, se apaga solo tras inactividad y cobra por segundo activo.

La capa de limpieza es donde se resuelven los cuatro problemas de calidad detectados en la exploración: el casteo de `end_station_id` a entero, el tratamiento de los nulos de destino, el marcado de duraciones anómalas y el `left join` contra el catálogo con etiqueta de respaldo para las estaciones que no figuran en él. La capa plata materializa la proyección de cuatro columnas con tipos reducidos que produjo las mejoras de la Fase 3.

La nomenclatura de capas es medallón (bronce/plata/oro), el estándar de facto para pipelines de ingesta incremental sobre un lakehouse. El catálogo de estaciones se une en la capa plata, durante la misma limpieza: las tres preguntas lo necesitan, y unirlos ahí evita repetir el `join` en la capa oro. Los datos se particionan por año-mes de `start_rental_date_time`, alineado con la cadencia mensual de ingesta, así que cada corrida del job solo toca la partición del mes que entra.

10. Análisis de costos

El análisis cubre dos cosas distintas: el costo de operar el pipeline ETL propuesto en la Sección 9 sobre Databricks + Azure, y el costo ya medido de la optimización de la Fase 3. Los precios son los públicos y actuales de las calculadoras oficiales de [Azure Databricks](#) y [Azure Data Lake Storage Gen2](#) para la región `us-east` (Este de EE. UU.), consultados en septiembre de 2026. No se espera exactitud, sino que el desglose sea razonable, esté sustentado y use tarifas reales en vez de estimaciones inferidas.

Supuestos del escenario:

- Proveedor: Databricks sobre Microsoft Azure, tier Premium, región East US, precios *pay-as-you-go* sin descuentos por compromiso.
- Frecuencia: batch mensual, con un archivo del tamaño de la versión S (0.488 GB) por corrida. El estado estable se alcanza en el mes 10, cuando la capa bronce llega al tamaño de la versión XL (4.725 GB).

- La capa plata mantiene la razón de reducción de la Fase 3, 53× frente al CSV. El Delta acumulado en el mes 10 pesa ~89 MB.
- ETL en un nodo `Standard_DS3_v2` (4 vCPU, 14 GB RAM, 0.75 DBU) de tipo *Jobs Compute*, con 10 minutos por corrida (arranque de clúster incluido).
- Consumo contra un *warehouse* Databricks SQL Serverless 2X-Small (4 DBU) que se apaga solo tras inactividad. Se asumen 5 minutos de uso mensual.

10.1. Costo del pipeline en la nube (mensual, estado estable)

Cuadro 17: Desglose de costo mensual del pipeline en Databricks + Azure, mes 10 (estado estable)

Componente	Cálculo	Costo/mes	Fuente
Almacenamiento ADLS Gen2 (bronce+plata+oro)	$(4.725 + 0.089 + 0.005) \text{ GB} \times \$0.0208/\text{GB}$ (Hot, LRS)	\$0.100	[1]
Operaciones ADLS Gen2 (escritura/lectura mensuales)	$\sim 50 \text{ escrituras} \times \$0.0625/10\text{k} + \sim 5,000 \text{ lecturas} \times \$0.004/10\text{k}$	\$0.002	[1]
Cómputo ETL (Databricks Jobs Compute, DS3 v2, 1 corrida/mes)	$\$0.518/\text{hora}$ (VM + 0.75 DBU) $\times 10 \text{ min}$	\$0.086	[2]
Orquestación (Databricks Workflows)	Incluida en el cómputo del job, sin cargo de orquestador aparte	\$0.000	[2]
Catálogo de esquema (Unity Catalog)	Incluido en el workspace Premium a este volumen de tablas	\$0.000	[2]
Consulta (Databricks SQL Serverless, 2X-Small)	$\$2.80/\text{hora} \times 5 \text{ min/mes de uso}$	\$0.233	[2]
Transferencia de salida	Muy por debajo de los 100 GB/mes gratuitos de Azure	\$0.000	[3]
Total estimado		\$0.42/mes	
[1] azure.microsoft.com/pricing/details/storage/data-lake [2] azure.microsoft.com/pricing/details/databricks [3] azure.microsoft.com/pricing/details/bandwidth			

El total sigue siendo minúsculo (~\$5/año) porque todo el histórico del dataset cabe en menos de 5 GB. Esa es en sí misma una conclusión relevante: **a esta escala, el costo de nube no es un problema**. Lo que domina el presupuesto es la decisión de diseño (Delta vs. CSV, cuánto tiempo queda encendido el warehouse), no el gasto en infraestructura. Esto es consistente con el hallazgo de la Fase 3: la representación de los datos importa más que la cantidad de recursos que se les asigna.

Databricks cuesta más que un equivalente sobre servicios nativos de nube a este volumen, y la causa es identificable. Un diseño equivalente sobre S3 + Glue + Athena rondaría \$0.27/mes. Aquí sale \$0.42/mes. El almacenamiento es casi igual (ambos ~\$0.10). La diferencia está en el consumo: un motor facturado por *terabyte escaneado* (Athena) sale más barato a este volumen que uno facturado por *tiempo encendido* (Databricks SQL Serverless, con tarifa mínima de \$2.80/hora). La brecha se cierra o se invierte en cuanto crece el volumen de consultas concurrentes, que es el escenario para el que Databricks SQL está diseñado.

Sensibilidad a la escala. Si el sistema creciera 200 veces (~945 GB acumulados), el almacenamiento en bronce pasaría a $\approx \$19.7/\text{mes}$ (sigue en el primer escalón de tarifa) y el cómputo ETL,

asumiendo que Spark escala el job a unos 100 minutos, a ~\$0.86/mes. El costo dejaría de ser trivial, pero seguiría siendo pequeño frente al tiempo de persona que cuesta reproducir el análisis sin el artefacto optimizado.

10.2. Costo ya medido: cómputo local y tiempo de persona

Costo en almacenamiento (medido). El CSV original de la versión XL pesa 4,725 MB. El Parquet optimizado pesa 89 MB y el CSV estrecho para SQLite pesa 442 MB. La reducción es de 53× y 10.7× respectivamente.

Costo en cómputo local (medido). El ETL de la Fase 3 cuesta entre 2.6 s y 14.8 s según la máquina y la versión. El ahorro por corrida completa del análisis va de 24.6 s (DuckDB, XL) a 191.9 s (Pandas, XL). La amortización ocurre en una fracción de la primera corrida.

Costo en tiempo de persona. Pc_Martha perdió 17 minutos en una ejecución que terminó fallando. Ese tipo de costo no aparece en ninguna tabla de benchmark ni en la tabla de costos de nube, pero es real y recurrente cada vez que alguien reproduce el análisis sin el artefacto optimizado.

Si el volumen de consultas creciera de forma sostenida, conviene migrar el warehouse de Databricks SQL de Serverless a capacidad reservada, que baja el costo por hora a cambio de tenerlo encendido de forma predecible; a este volumen de consultas mensuales no se justifica.

11. Problemas encontrados

Cuadro 18: Problemas encontrados durante el desarrollo

#	Problema	Cómo se resolvió
1	Las tres herramientas numeran los días de la semana distinto. Pandas <code>dt.dayofweek</code> arranca en lunes = 0; DuckDB <code>dayofweek()</code> y SQLite <code>strftime('%w')</code> arrancan en domingo = 0. Los resultados no coincidían aunque el total sí.	Se unificó todo a lunes = 0 con <code>isodow() - 1</code> en DuckDB y <code>(strftime('%w')+6)%7</code> en SQLite. La validación cruzada se agregó justamente para cazar este tipo de error.
2	end_station_id se infiere como DOUBLE porque tiene nulos, mientras <code>start_station_id</code> es entero. Al agrupar por el par, los identificadores no cruzaban: 529.0 contra 529.	<code>CAST(... AS BIGINT)</code> y <code>.astype("int64")</code> explícitos en las tres herramientas antes de agrupar.
3	FULL OUTER JOIN no existe en SQLite anterior a la versión 3.39. La consulta de Q2, escrita originalmente para DuckDB, fallaba con error de sintaxis en instalaciones de SQLite más antiguas durante el desarrollo.	Se reescribió con un CTE <code>ids</code> (unión de los identificadores de origen y destino) más dos <code>LEFT JOIN</code> , y se usó la misma forma en DuckDB para que las consultas fueran estructuralmente comparables.
4	La ingesta a SQLite era lentísima con el <code>journal</code> y el <code>fsync</code> por defecto.	<code>PRAGMA journal_mode=OFF, synchronous=OFF, cache_size=-262144</code> e inserción por lotes de 200,000 filas con <code>executemany</code> , en vez de un <code>INSERT</code> por fila.
5	SQLite no conserva el CSV cargado entre consultas , a diferencia de Pandas y DuckDB.	Se adoptó el protocolo de ejecución independiente y se aplicó a las tres herramientas, para que la comparación fuera simétrica.
6	El import de pyarrow inflaba el tiempo de carga del Parquet. Pandas lo importa en el primer <code>read_parquet()</code> y ese import en frío se contaba como lectura de datos.	Se movió el import fuera de todo bloque cronometrado.
7	Los artefactos pesados en carpetas sincronizadas distorsionaban los tiempos , porque la sincronización compite por I/O.	Los <code>.db</code> y <code>.parquet</code> se escriben en disco local, no en la carpeta de nube.

Cuadro 18 (continuación): Problemas encontrados durante el desarrollo

#	Problema	Cómo se resolvió
8	Pc_Martha (15.7 GB) falló en XL tras 17 minutos sin completar la lectura del CSV.	Se registró como resultado: es el dato que define el umbral de Big Data para ese equipo. Se corrió una segunda pasada sin XL para completar las demás versiones.
9	La gráfica de impacto suma tiempos sin verificar que ambas etapas tengan las mismas preguntas completadas. Con ejecuciones omitidas, la barra base queda corta y sugiere que la optimización empeoró el rendimiento.	Se detectó en SQLite XL sobre Pc_Nahin y se corrigió comparando pregunta contra pregunta (§6.5).

12. Limitaciones metodológicas

Tres advertencias condicionan cómo deben leerse los números de este informe.

El pico de RAM no es comparable entre macOS y Windows. Pandas en XL reporta 4,522 MB en Pc_Jesus y 12,096 MB en Pc_Nahin. macOS comprime páginas de memoria y el RSS que reporta `psutil` no las contabiliza. Los números de RAM sirven para comparar herramientas **dentro** de una misma máquina, no entre sistemas operativos.

El equipo de mayores especificaciones fue el más lento. Pc_Nahin (Core Ultra 9, 40 GB) tarda de 2 a 4 veces más que Pc_Jesus (8 GB) en todas las herramientas, incluida la carga pura de CSV con DuckDB (36 s contra 8 s en XL). Es una brecha de entrada/salida, no de CPU ni memoria: carpeta sincronizada con la nube, antivirus escaneando 4.7 GB en cada lectura, o las tres versiones corridas en una sola sesión sin liberar memoria. **No se verificó cuál aplica**, así que los tiempos absolutos de ese equipo son una cota superior.

Las versiones de librerías difieren entre equipos. Python va de 3.12.10 a 3.14.3 y pandas de 3.0.1 a 3.0.5. No explica diferencias de orden de magnitud, pero introduce ruido en comparaciones finas. Por eso las conclusiones se apoyan en órdenes de magnitud y fallos categóricos, no en márgenes estrechos.

13. Conclusiones

Big Data no es un tamaño, es una relación. El mismo archivo de 38.2 millones de filas fue imposible en una máquina de 15.7 GB de RAM y manejable en una de 8 GB. La frontera no la marca una cifra de filas o gigabytes, sino la interacción entre volumen, representación de los datos y equipo.

La representación es la palanca más barata. El paso de CSV a Parquet con proyección y tipos reducidos costó entre 2.6 y 14.8 segundos por versión y multiplicó el rendimiento hasta 110×. Más importante: movió el umbral de viabilidad. Un equipo que no podía procesar la versión completa pasó a hacerlo en 6 segundos, sin agregar hardware.

La arquitectura del motor importa más que sus especificaciones. DuckDB, columnar y vectorizado, resolvió en 2.7 segundos sobre 8 GB de RAM lo que a SQLite, orientado a filas y con el mismo artefacto optimizado, le tomó cerca de 20 minutos sobre 40 GB. Índices y PRAGMA mejoran a SQLite, pero un B-tree no convierte un motor OLTP en columnar.

La carga, no la consulta, es el cuello de botella. Entre el 57 % y el 97 % del tiempo total se va en leer el archivo; una optimización que ignore esto ataca el problema equivocado.

Sobre el sistema de bicicletas. El uso es bimodal en días laborables (picos a las 08:00 y 17:00-18:00) y unimodal y recreativo en fin de semana (máximo a las 14:00). El desbalance sigue un patrón radial: estaciones de tren y zonas residenciales se vacían, distritos de oficinas se saturan. El tráfico está concentrado pero no dominado: las 1,000 rutas más usadas suman el 9.6 % de los viajes, y las nueve primeras son paseos circulares dentro de parques.